Trabalho Prático: Propriedades Assintóticas de Estimadores

Estudo de Simulação para o Modelo Gama: EMV vs. Momentos

Disciplina: Inferência Estatística
Semestre: 2026/2

Objetivo

Avaliar e comparar empiricamente as propriedades assintóticas dos Estimadores de Máxima Verossimilhança (EMV) e dos Estimadores de Momentos (EM) para a distribuição Gama. Por meio de um estudo de simulação de Monte Carlo, os alunos devem implementar estimação numérica e analítica, construir intervalos de confiança de 95% e calcular métricas de desempenho (viés, variância, erro quadrático médio, cobertura, largura e equilíbrio de caudas).

1 Modelo Estatístico

Seja $X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Gamma}(\alpha, \beta)$, com função de densidade

$$f(x; \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}, \quad x > 0,\ \alpha > 0,\ \beta > 0,$$

onde α é o parâmetro de *forma* e β o de *escala*. Tem-se $\mathbb{E}[X] = \alpha\beta$ e $\text{Var}(X) = \alpha\beta^2$.

Estimadores de Máxima Verossimilhança

A log-verossimilhança é

$$\ell(\alpha, \beta) = -n\alpha \ln \beta - n \ln \Gamma(\alpha) + (\alpha - 1) \sum_{i=1}^{n} \ln x_i - \frac{1}{\beta} \sum_{i=1}^{n} x_i.$$

As equações de escore são:

$$U_\alpha(\alpha, \beta) = -n \ln \beta - n\psi(\alpha) + \sum_{i=1}^{n} \ln x_i, \tag{1}$$

$$U_\beta(\alpha, \beta) = -\frac{n\alpha}{\beta} + \frac{1}{\beta^2} \sum_{i=1}^{n} x_i, \tag{2}$$

onde $\psi(\cdot)$ é a função digamma. O EMV satisfaz $\hat{\beta}_{\text{MLE}} = \bar{X}/\hat{\alpha}_{\text{MLE}}$ e $\hat{\alpha}_{\text{MLE}}$ resolve a equação não-linear

$$\ln \hat{\alpha}_{\text{MLE}} - \psi(\hat{\alpha}_{\text{MLE}}) = \ln \bar{X} - \overline{\ln X}. \tag{3}$$

Estimadores de Momentos

Igualando os dois primeiros momentos amostrais aos populacionais:

$$\bar{X} = \alpha\beta, \quad S^2 = \alpha\beta^2 \implies \hat{\alpha}_{\text{MM}} = \frac{\bar{X}^2}{S^2}, \quad \hat{\beta}_{\text{MM}} = \frac{S^2}{\bar{X}},$$

onde $S^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2$ (variância com divisor n). Não requer otimização numérica e possui forma fechada.

2 Propriedades Assintóticas e Intervalos de Confiança

Ambos os estimadores são consistentes e assintoticamente normais. Para o EMV:

$$\sqrt{n}\Big((\hat{\theta}_{\text{MLE}} - \theta\Big) \xrightarrow{d} \mathcal{N}_2\Big(\mathbf{0}, \mathcal{I}^{-1}(\alpha,\beta)\Big), \quad \mathcal{I}(\alpha,\beta) = \begin{pmatrix} \psi_1(\alpha) & 1/\beta \\ 1/\beta & \alpha/\beta^2 \end{pmatrix},$$

com $\psi_1(\cdot)$ a função trigamma. Para os Momentos, via Método Delta:

$$\sqrt{n}\Big((\hat{\theta}_{\text{MM}} - \theta\Big) \xrightarrow{d} \mathcal{N}_2\Big(\mathbf{0}, \Sigma_{\text{MM}}\Big), \quad \Sigma_{\text{MM}} = \begin{pmatrix} \alpha(2+\alpha) & \beta(2+\alpha) \\ \beta(2+\alpha) & \beta^2(2+\alpha)/\alpha \end{pmatrix}.$$

Para cada réplica $j = 1, \ldots, R$, construímos ICs assintóticos de 95% para $\theta \in \{\alpha, \beta\}$:

- **EMV-Fisher (MLE-IF):** $\hat{\theta} \pm z_{0.975}\sqrt{\Big[n\mathcal{I}(\hat{\theta}_{\text{MLE}})\Big]^{-1}_{kk}}$
- **EMV-Observada (MLE-IO):** $\hat{\theta} \pm z_{0.975}\sqrt{\Big[-\nabla^2\ell(\hat{\theta}_{\text{MLE}})\Big]^{-1}_{kk}}$
- **Momentos (MM):** $\hat{\theta}_{\text{MM}} \pm z_{0.975}\sqrt{\Big[\widehat{\Sigma}_{\text{MM}}/n\Big]_{kk}}$

com $z_{0.975} \approx 1.96$ e $\widehat{\Sigma}_{\text{MM}}$ obtido por substituição dos parâmetros por suas estimativas de momentos.

3 Desenho da Simulação

1. Fixe os valores verdadeiros: $\alpha_0 = 2$, $\beta_0 = 3$.
2. Gere $R = 10.000$ réplicas independentes para cada tamanho amostral $n \in \{20, 50, 100, 200, 500\}$.
3. Para cada réplica:
   a) Calcule $(\hat{\alpha}_{\text{MLE}}, \hat{\beta}_{\text{MLE}})$ por otimização numérica.
   b) Calcule $(\hat{\alpha}_{\text{MM}}, \hat{\beta}_{\text{MM}})$ analiticamente.
   c) Estime os erros padrão para os três métodos (MLE-IF, MLE-IO, MM).
   d) Construa os ICs de 95% para α e β.
4. Para cada n e método, calcule:

- Média dos estimadores: $\overline{\hat{\theta}}$
- Média dos erros padrão estimados: $\overline{\widehat{\mathrm{SE}}}$
- Desvio padrão dos estimadores: $\mathrm{SD}(\hat{\theta})$
- Viés de Monte Carlo: MC-viés $= \frac{1}{R}\sum_{j=1}^{R}(\hat{\theta}^{(j)} - \theta_0)$
- Erro Quadrático Médio de Monte Carlo: MC-MSE $= \frac{1}{R}\sum_{j=1}^{R}(\hat{\theta}^{(j)} - \theta_0)^2$
- Largura média dos ICs: $\overline{W}$
- Probabilidade de cobertura: $PC = \frac{1}{R}\sum_{j=1}^{R}\mathbb{I}(\theta_0 \in [LI_j, LS_j])$
- Erros de cauda: $\hat{\alpha}_1 = \frac{1}{R}\sum \mathbb{I}(\theta_0 < LI_j)$, $\hat{\alpha}_2 = \frac{1}{R}\sum \mathbb{I}(\theta_0 > LS_j)$

Orientações Computacionais

- Desenvolva o codigo em R o algoritmo de Newton-Rapson e Fisher Escoring para resolver a equação em (3).
- Para estabilidade numérica, otimize em escala logarítmica: trabalhe com $\eta = \ln\alpha$, $\zeta = \ln\beta$.
- Mantenha `set.seed()` fixo para reproducibilidade.

Entrega Esperada

1. **Código fonte** em `R` (comentado, vetorializado e reprodutível).
2. **Relatório em PDF** contendo:
   - Tabela consolidada com todas as métricas por n e método.
   - Gráficos comparativos: (i) $\overline{\mathrm{MSE}}$ vs n, (ii) PC vs n, (iii) $\overline{W}$ vs n, para EMV e Momentos.
   - Discussão sobre: eficiência relativa (perda de eficiência dos Momentos), convergência numérica vs custo computacional, comportamento das caudas ($\hat{\alpha}_1$ vs $\hat{\alpha}_2$) e limites da aproximação normal para n pequenos.
3. **Análise Crítica:** Explique por que os Momentos são menos eficientes que o EMV, mas podem ser preferidos em certos contextos. Comente sobre a robustez dos ICs baseados na Informação Observada vs Fisher.